

**Prediksi Daya Aktif Photovoltaic (PV)
menggunakan Temporal Fusion Transformer di
Pulau Selayar**

Proposal Tugas Akhir

IF-47-DSIS.05

103012300483

Irham Kurnia Putra



Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2026

Lembar Persetujuan

**Prediksi Daya Aktif Photovoltaic (PV) menggunakan Temporal
Fusion Transformer di Pulau Selayar**

***Photovoltaic (PV) Active Power Prediction using Temporal
Fusion Transformer on Selayar Island***

NIM: 103012300483

Irham Kurnia Putra

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Informatika
Fakultas Informatika Universitas Telkom

Bandung, 25 Mei 2026
Menyetujui

Calon Pembimbing

(Dr Didit Adytia, S.Si.,M.Si)
NIP: 16830005

Abstrak

Ketidakpastian keluaran daya Pembangkit Listrik Tenaga Surya (PLTS) akibat variabilitas cuaca menjadi tantangan operasional pada *microgrid* kepulauan terisolasi seperti Pulau Selayar, sistem tersebut mengintegrasikan PLTS 1,3 MW, *Battery Energy Storage System* (BESS), dan sebelas unit PLTD. Tanpa informasi prediksi yang andal, perencanaan operasi harian sistem kelistrikan lokal menjadi sulit dilakukan karena kontribusi daya PV dapat berubah mengikuti kondisi radiasi matahari dan variabel atmosfer. Penelitian ini bertujuan menghasilkan dan mengevaluasi model prediksi daya aktif PV *day-ahead* 24 jam menggunakan *Temporal Fusion Transformer* (TFT) sebagai dukungan informasi awal bagi perencanaan operasi PLTS, BESS, dan PLTD di Pulau Selayar. TFT digunakan karena dirancang untuk prediksi deret waktu multivariat dan *multi-horizon*, mampu membedakan *observed historical inputs* dan *known future inputs*, serta menyediakan mekanisme interpretabilitas melalui *Variable Selection Network* dan *attention*. Data yang digunakan mencakup data operasional PLTS Pulau Selayar periode Maret 2022 hingga Agustus 2023 sebagai variabel target, data *irradiance sensor* sebagai fitur historis lokal, serta data cuaca ERA5 *reanalysis* sebagai variabel eksogen historis. Dalam rancangan eksperimen, *known future inputs* dibatasi pada fitur waktu dan fitur astronomis yang dapat dihitung secara deterministik, sedangkan variabel ERA5 masa depan tidak digunakan sebagai masukan masa depan untuk menghindari *data leakage*. Kinerja TFT dievaluasi melalui perbandingan dengan *persistence*, LSTM, dan Transformer standar, dengan Transformer standar diposisikan sebagai *baseline* utama berbasis *attention*. Evaluasi dilakukan menggunakan MAE dan RMSE sebagai metrik utama, serta koefisien determinasi (R^2) sebagai metrik pendukung. Hipotesis awal penelitian ini adalah bahwa TFT mampu menghasilkan prediksi daya aktif PV *day-ahead* 24 jam dengan kesalahan prediksi yang lebih rendah dibandingkan model pembanding, sekaligus memberikan informasi mengenai kontribusi variabel masukan melalui mekanisme interpretabilitas model.

Kata Kunci: *temporal fusion transformer*, prediksi daya *photovoltaic*, *day-ahead forecasting*, Transformer standar, *microgrid* terisolasi, variabel cuaca eksogen, interpretabilitas model.

Daftar Isi

Abstrak	i
Daftar Isi	ii
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	4
1.5 Hipotesis	4
1.6 Rencana Kegiatan	5
1.7 Jadwal Kegiatan	6
II Kajian Pustaka	7
2.1 Tinjauan Pustaka	7
2.1.1 Strategi Penelusuran Literatur dan Penegasan Gap . . .	7
2.1.2 Penelitian Terdahulu	8
2.2 Dasar Teori	10
2.2.1 PLTS	10
2.2.2 Daya Aktif PV	11
2.2.3 Sistem Microgrid Terisolasi Pulau Selayar	11
2.2.4 Variabel Cuaca Eksogen	12
2.2.5 PV Forecasting	12
2.2.6 Day-Ahead Forecasting	12
2.2.7 Metode Prediksi Daya PV	13
2.2.8 <i>Temporal Fusion Transformer</i> (TFT)	14
2.2.9 Baseline Model	17
2.2.9.1 Persistence	17
2.2.9.2 Long Short-Term Memory	18
2.2.9.3 Transformer	18
2.2.10 Metrik Evaluasi	18
2.3 Posisi Penelitian	19

III Metodologi	21
3.1 Desain Penelitian	21
3.2 Alur Pemodelan	22
3.3 Rencana Kebutuhan Data	23
3.4 Pra-pemrosesan Data	24
3.4.1 Penyelarasan dan Integrasi Data	24
3.4.2 Pembersihan dan Penanganan Nilai Hilang	24
3.4.3 Deteksi Anomali dan Normalisasi Data	25
3.4.4 Rekayasa Fitur	25
3.5 Pembagian Data	25
3.6 Skenario Pengujian	26
3.7 Algoritma	27
3.7.1 Algoritma Umum Prediksi Daya Aktif PV	27
3.7.2 Model Baseline	28
3.7.3 Model Temporal Fusion Transformer	28
3.7.4 Analisis Interpretabilitas TFT	29
3.8 Evaluasi dan Analisis Hasil	29
3.9 Perangkat Penelitian	30
Daftar Pustaka	32
Lampiran	34

Bab I

Pendahuluan

1.1 Latar Belakang

Untuk mencapai target emisi nol bersih (*Net Zero Emission*) pada tahun 2050, transisi ke energi terbarukan menjadi solusi utama dalam menghadapi krisis lingkungan dan penipisan sumber daya fosil [1, 2]. Indonesia, sebagai negara tropis, memiliki potensi energi surya yang sangat melimpah untuk mendukung ketahanan energi nasional, terutama dalam penyediaan listrik bagi wilayah-wilayah yang tidak terjangkau oleh jaringan listrik utama.

Meskipun menjanjikan, transisi energi terbarukan melalui Pembangkit Listrik Tenaga Surya (PLTS) memiliki permasalahan mendasar, yaitu ketersediaannya yang sangat bergantung pada variabel cuaca dan kondisi alam [3, 4]. Hal ini menyebabkan energi listrik yang dihasilkan tidak bisa dikontrol sepenuhnya atau bersifat *non-dispatchable*, berbeda dengan energi tak terbarukan yang pasokannya dapat diatur sesuai kebutuhan operasional. Sifatnya yang *variable* dan *intermittent* ini menyebabkan fluktuasi daya yang tiba-tiba akibat perubahan radiasi matahari, tutupan awan, atau kondisi atmosfer lainnya [5].

Tantangan tersebut dapat terjadi pada siklus harian, khususnya saat malam hari di mana sistem harus mengandalkan energi yang disimpan dalam sistem penyimpanan energi baterai (*Battery Energy Storage System* atau BESS) selama siang hari [6]. Permasalahan krusial muncul apabila energi yang diserap di siang hari tidak mencukupi untuk mengisi baterai guna mendukung beban malam hari, sehingga sistem memerlukan pasokan daya dari sumber lain seperti mesin diesel (PLTD). Oleh karena itu, diperlukan informasi prediksi yang akurat agar penggunaan sumber daya cadangan dapat disesuaikan secara tepat dengan kebutuhan, guna meminimalisir penggunaan bahan bakar fosil dan menjaga keseimbangan pasokan daya.

Untuk mengatasi ketidakpastian tersebut, diperlukan *PV Forecasting* untuk mengestimasi keluaran daya di masa depan guna mendukung perencanaan operasi harian sistem kelistrikan [7]. Prediksi yang akurat memungkinkan operator untuk menyeimbangkan pasokan dan permintaan serta mengoptimalkan penjadwalan unit pembangkit cadangan. Berbagai pendekatan telah diterapk-

an dalam bidang ini, mulai dari model fisik berdasarkan hukum atmosfer, metode statistik tradisional seperti ARIMA, dan penggunaan teknik kecerdasan buatan (*artificial intelligence*) seperti *Machine Learning* dan *Deep Learning*.

Seiring kemajuan teknologi, pendekatan *deep learning* kini menjadi fokus utama karena kemampuannya menangkap pola nonlinier yang kompleks pada data deret waktu surya yang besar [8, 7]. Meskipun arsitektur sekuensial seperti *Long Short-Term Memory* (LSTM) telah lama menjadi standar, model berbasis *Transformer* dengan mekanisme *attention* mulai menunjukkan performa unggul dalam menangkap ketergantungan temporal jangka panjang yang sering kali sulit dijangkau oleh model tradisional [9, 8]. Sebagai evolusi yang lebih spesifik, *Temporal Fusion Transformer* (TFT) hadir dengan keunggulan yang melampaui arsitektur *Transformer* standar, terutama dalam kemampuannya mengolah berbagai jenis variabel masukan dengan membedakan informasi historis dan informasi masa depan yang sudah diketahui [10, 11]. Berbeda dengan *Transformer* standar yang cenderung memproses seluruh data secara seragam, TFT mampu mengidentifikasi faktor cuaca yang paling relevan secara otomatis, sehingga menghasilkan prediksi yang tidak hanya lebih akurat tetapi juga transparan [12, 13]. Keunggulan ini memberikan penjelasan lebih mendalam bagi pengelola sistem kelistrikan mengenai alasan di balik fluktuasi prediksi daya surya, hal ini tentu untuk meningkatkan kepercayaan terhadap keputusan operasional yang diambil [10, 13].

Secara implementasi, penelitian ini mengambil studi kasus di Pulau Selayar, Sulawesi Selatan, untuk mengevaluasi efektivitas model tersebut pada sistem *microgrid* terisolasi yang tidak terhubung dengan jaringan listrik utama [5]. Sistem kelistrikan di pulau ini mengandalkan gabungan energi dari pembangkit tenaga surya, sistem penyimpanan energi baterai (*Battery Energy Storage System*), dan pembangkit diesel untuk melayani kebutuhan beban lokal. Dalam kondisi terisolasi, fluktuasi keluaran daya PV yang tidak terprediksi dapat langsung memengaruhi stabilitas daya lokal karena tidak adanya dukungan kompensasi dari jaringan besar [5, 6]. Oleh karena itu, penerapan model prediksi yang cerdas dan transparan menjadi faktor krusial bagi keberlangsungan operasi sistem kelistrikan di pulau tersebut guna menyeimbangkan pasokan dan permintaan energi secara real-time [5, 7].

Penelitian ini bertujuan untuk menerapkan dan mengevaluasi model *Temporal Fusion Transformer* (TFT) untuk memprediksi daya aktif PV secara *day-ahead* (24 jam ke depan) di Pulau Selayar [10, 11]. TFT dipilih karena kemampuannya yang spesifik dalam menangani prediksi *multi-horizon* serta kemampuannya membedakan antara input historis (*past inputs*) dan input masa depan yang sudah diketahui (*known future inputs*). Selain akurasi, keunggulan utama TFT dalam penelitian ini adalah mekanisme interpretabilitas yang memungkinkan analisis mengenai variabel cuaca apa saja yang paling berkontribusi signifikan terhadap hasil prediksi daya aktif PV di lokasi terse-

but.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan mengimplementasikan arsitektur *Temporal Fusion Transformer* (TFT) untuk memprediksi daya aktif PV secara *day-ahead* (24 jam ke depan) di Pulau Selayar dengan mengintegrasikan variabel histori daya, data cuaca multivariat, dan fitur waktu?
2. Bagaimana performa akurasi model TFT jika dibandingkan dengan model *baseline* seperti *Persistence* dan *Long Short-Term Memory* (LSTM) dalam menangani karakteristik data yang bersifat *variable* dan *intermittent* pada *microgrid* Pulau Selayar?
3. Sejauh mana mekanisme interpretabilitas pada model TFT (*Variable Selection Network* dan *attention*) dapat mengidentifikasi variabel cuaca yang paling berpengaruh terhadap fluktuasi produksi daya listrik di lokasi penelitian?

1.3 Tujuan Penelitian

Tujuan utama penelitian ini adalah menghasilkan dan mengevaluasi model prediksi daya aktif PV *day-ahead* 24 jam menggunakan *Temporal Fusion Transformer* sebagai dukungan informasi bagi perencanaan operasi harian sistem PLTS pada *microgrid* Pulau Selayar.

Secara lebih spesifik, tujuan penelitian ini adalah sebagai berikut:

1. Membangun model prediksi berbasis *Temporal Fusion Transformer* (TFT) yang mampu mengolah input masa lalu dan input masa depan yang diketahui untuk menghasilkan estimasi daya PV yang akurat bagi sistem kelistrikan Pulau Selayar.
2. Melakukan evaluasi komparatif menggunakan metrik **MAE** dan **RMSE** untuk membuktikan keunggulan model berbasis *attention* dibandingkan model sekuensial tradisional dalam konteks prediksi energi surya.
3. Menganalisis kontribusi relatif dari berbagai **variabel meteorologi** (seperti iradiasi dan suhu) terhadap hasil prediksi melalui fitur transparansi model guna mendukung pengambilan keputusan operasional manajemen energi.

1.4 Batasan Masalah

Berdasarkan latar belakang dan rumusan masalah yang telah diuraikan, penelitian ini memiliki ruang lingkup dan batasan tertentu agar pembahasan lebih terarah dan sasaran penelitian dapat tercapai secara spesifik [5]. Batasan masalah pada penelitian ini diuraikan sebagai berikut:

1. **Objek dan Lokasi Penelitian:** Penelitian ini dibatasi pada prediksi daya aktif *photovoltaic* (PV) pada sistem PLTS di Pulau Selayar, Sulawesi Selatan, yang beroperasi sebagai *microgrid* terisolasi
2. **Sumber dan Periode Data:** Data yang digunakan terdiri atas data historis operasional PLTS Pulau Selayar dan data cuaca reanalisis ERA5. Rentang waktu data dibatasi pada periode Maret 2022 hingga Agustus 2023.
3. **Variabel Masukan Model:** Masukan model dibatasi pada histori daya aktif PV, variabel meteorologi dari ERA5 (seperti radiasi matahari, suhu udara, dan tutupan awan), serta fitur waktu siklik. Penelitian ini tidak mencakup penggunaan data citra satelit *real-time* atau sensor lokal tambahan di luar yang tersedia pada dataset.
4. **Horizon Prediksi:** Fokus penelitian diarahkan pada skenario *day-ahead forecasting* dengan jangka waktu 24 jam ke depan. Oleh karena itu, penelitian tidak membahas prediksi jangka panjang atau *very short-term intraday*.
5. **Arsitektur Model:** Pengembangan model *Deep Learning* dibatasi pada implementasi arsitektur *Temporal Fusion Transformer* (TFT) dan membandingkannya dengan model *baseline* seperti *Persistence* dan *Long Short-Term Memory* (LSTM).
6. **Parameter Evaluasi:** Pengujian keberhasilan model hanya diukur menggunakan metrik kuantitatif deret waktu, yaitu *Mean Absolute Error* (MAE) dan *Root Mean Square Error* (RMSE).

1.5 Hipotesis

Hipotesis yang diajukan sebagai dasar pemecahan masalah dalam penelitian Tugas Akhir ini adalah:

1. Penerapan arsitektur *Temporal Fusion Transformer* (TFT) diprediksi akan menghasilkan performa prediksi daya aktif PV yang lebih superior dan stabil dibandingkan dengan metode *baseline* (*Persistence* dan LSTM). Hal ini didasarkan pada kemampuan khusus TFT dalam membedakan masukan historis (*past inputs*) dengan masukan masa depan

yang diketahui (*known future inputs*) serta kemampuannya menangkap ketergantungan temporal jangka panjang melalui mekanisme *attention*.

2. Mekanisme interpretabilitas pada TFT, khususnya melalui *Variable Selection Network* (VSN), diprediksi secara efektif mampu mengidentifikasi dan memberikan bobot kontribusi variabel cuaca (seperti iradiasi dan suhu) yang paling signifikan terhadap fluktuasi daya aktif PV di Pulau Selayar. Hal ini akan memberikan transparansi pada model yang biasanya bersifat *black-box*, sehingga meningkatkan keandalan informasi bagi pengelola sistem kelistrikan.

1.6 Rencana Kegiatan

Rencana kegiatan dalam penelitian ini disusun dalam beberapa tahapan sebagai berikut:

1. Studi Literatur

Mengkaji teori dan penelitian terdahulu terkait prediksi daya PV, *time series forecasting*, *Temporal Fusion Transformer*, *microgrid* terisolasi, serta pengaruh variabel cuaca terhadap keluaran daya PV.

2. Pengumpulan Data

Mengumpulkan data daya aktif PV dan *irradiance* sensor dari sistem PLTS Pulau Selayar, serta data cuaca ERA5 *reanalysis* yang mencakup radiasi matahari permukaan, radiasi termal permukaan, suhu udara, suhu titik embun, presipitasi, komponen angin, hembusan angin, dan tinggi lapisan batas atmosfer.

3. Pra-pemrosesan Data

Melakukan penyelarasan *timestamp*, pembersihan data, penanganan nilai hilang, deteksi anomali, normalisasi atau standarisasi, serta pembagian data secara kronologis menjadi data latih, validasi, dan uji.

4. Rekayasa Fitur

Membentuk fitur tambahan yang relevan untuk prediksi daya PV, seperti fitur waktu siklik, fitur posisi matahari, *wind speed*, selisih suhu dan titik embun, serta fitur turunan lain yang digunakan sebagai masukan historis model.

5. Pembentukan Dataset Time Series

Membentuk dataset menggunakan pendekatan *sliding window*, dengan input historis sepanjang L jam dan target prediksi daya aktif PV selama 24 jam ke depan.

6. Perancangan dan Implementasi Model

Mengimplementasikan *Temporal Fusion Transformer* sebagai model utama, Transformer standar sebagai *baseline* utama berbasis *attention*, serta *persistence* dan LSTM sebagai pembanding pendukung.

7. Evaluasi dan Analisis Hasil

Mengevaluasi kinerja model menggunakan MAE dan RMSE, membandingkan TFT dengan *baseline*, serta menganalisis interpretabilitas TFT melalui bobot *Variable Selection Network* dan *attention*.

8. Penyusunan Laporan

Menyusun laporan tugas akhir berdasarkan hasil eksperimen, analisis, penarikan kesimpulan, dan penyusunan saran penelitian.

1.7 Jadwal Kegiatan

Jadwal pelaksanaan penelitian disusun berdasarkan tahapan kegiatan yang telah direncanakan. Tabel 1.1 menunjukkan jadwal kegiatan proposal tugas akhir, dengan blok berwarna yang menandai periode pelaksanaan setiap kegiatan.

Tabel 1.1: Jadwal kegiatan proposal tugas akhir

No	Kegiatan	Bulan 1	Bulan 2	Bulan 3	Bulan 4	Bulan 5	Bulan 6
1	Studi Literatur						
2	Pengumpulan Data						
3	Pra-pemrosesan Data						
4	Rekayasa Fitur						
5	Pembentukan Dataset <i>Time Series</i>						
6	Perancangan dan Implementasi Model						
7	Evaluasi dan Analisis Hasil						
8	Penyusunan Laporan						

Bab II

Kajian Pustaka

2.1 Tinjauan Pustaka

Tinjauan pustaka pada penelitian ini membahas penelitian terdahulu yang berkaitan dengan prediksi daya PV, penggunaan variabel cuaca eksogen, model *deep learning*, model berbasis *attention*, Temporal Fusion Transformer (TFT), serta relevansi prediksi PV terhadap sistem *microgrid* terisolasi. Kajian ini digunakan untuk menunjukkan posisi penelitian, gap penelitian, alasan pemilihan TFT, dan dasar penggunaan Transformer standar sebagai *baseline* utama berbasis *attention*. Fokus utama penelitian ini bukan hanya membandingkan model, tetapi menghasilkan prediksi daya aktif PV yang dapat menjadi dukungan informasi awal bagi perencanaan operasi harian sistem PLTS di Pulau Selayar.

2.1.1 Strategi Penelusuran Literatur dan Penegasan Gap

Untuk memperkuat perumusan gap penelitian, penelusuran literatur dilakukan secara terarah pada basis data publikasi ilmiah dan mesin pencari akademik, seperti Scopus, IEEE Xplore, ScienceDirect, MDPI, SpringerLink, dan Google Scholar. Kata kunci yang digunakan mencakup kombinasi istilah: “*Temporal Fusion Transformer*”, “*PV power forecasting*”, “*photovoltaic forecasting*”, “*day-ahead forecasting*”, “*microgrid*”, “*island microgrid*”, “*isolated microgrid*”, “*Indonesia*”, “*Southeast Asia*”, dan “*tropical climate*”. Penelusuran difokuskan pada publikasi lima tahun terakhir agar kajian merepresentasikan perkembangan mutakhir pada prediksi daya PV berbasis data.

Berdasarkan literatur yang berhasil ditelusuri dan dikaji, penelitian tentang prediksi daya PV berbasis TFT telah ditemukan pada beberapa konteks internasional, misalnya fasilitas PV di Jerman dan Australia [?], serta PV plant dengan penekanan pada interpretabilitas model [?]. Di kawasan Asia Tenggara, terdapat penelitian terkait prediksi energi surya atau radiasi surya pada iklim tropis, seperti studi di Java–Bali, Indonesia [?], prediksi daya PV pada iklim tropis Malaysia menggunakan model hibrida *deep learning* [?], dan pengembangan TFT untuk prediksi pembangkitan surya di Thailand [?]. Namun, pada kumpulan literatur yang ditinjau, belum ditemukan penelitian

yang secara khusus menguji TFT untuk prediksi daya aktif PV *day-ahead* 24 jam pada konteks *microgrid* kepulauan terisolasi Indonesia dengan karakteristik sistem seperti Pulau Selayar yang mengintegrasikan PLTS, BESS, dan PLTD [?]. Dengan demikian, gap penelitian ini tidak dinyatakan secara absolut sebagai ketiadaan penelitian serupa, melainkan sebagai keterbatasan bukti empiris yang ditemukan pada konteks lokasi, sistem kelistrikan, dan struktur input yang digunakan dalam penelitian ini.

2.1.2 Penelitian Terdahulu

Penelitian terdahulu digunakan untuk melihat perkembangan metode, objek, data, dan pendekatan yang telah digunakan dalam prediksi daya PV. Kajian ini juga digunakan untuk menunjukkan posisi penelitian yang dilakukan, khususnya dalam penerapan *Temporal Fusion Transformer* untuk prediksi daya aktif PV *day-ahead* 24 jam pada konteks *microgrid* kepulauan terisolasi Pulau Selayar. Penelitian terdahulu yang dikaji mencakup studi tentang prediksi daya PV berbasis TFT, LSTM, Transformer, variabel cuaca eksogen, konteks iklim tropis Indonesia dan Asia Tenggara, serta keterkaitan prediksi PV dengan operasi *microgrid* terisolasi [?, ?, ?, ?, ?, ?].

Tabel 2.1: Ringkasan penelitian terdahulu yang relevan

Peneliti/Tahun	Tujuan Penelitian	Metode	Hasil dan Relevansi
López Santos et al. [?]	Memprediksi daya PV <i>day-ahead</i> secara <i>multi-horizon</i> pada fasilitas PV di Jerman dan Australia.	TFT, ARIMA, MLP, LSTM, XGBoost.	TFT menunjukkan performa kompetitif dibandingkan beberapa model pembanding. Penelitian ini relevan sebagai dasar penggunaan TFT untuk prediksi daya PV <i>day-ahead</i> , tetapi belum membahas konteks <i>microgrid</i> kepulauan Indonesia.
Islam et al. [?]	Memprediksi keluaran PV plant dengan model yang dapat diinterpretasikan.	Temporal Fusion Transformer.	TFT mampu menghasilkan prediksi dan memberikan informasi interpretabilitas melalui bobot variabel. Relevan untuk analisis variabel berpengaruh dalam penelitian ini, tetapi tidak berfokus pada sistem kelistrikan pulau terisolasi.
Al-Dahidi et al. [?]	Melakukan prediksi PV <i>multi-step</i> menggunakan pendekatan <i>deep learning</i> .	TFT, TCN, MGU.	Menunjukkan bahwa TFT relevan untuk prediksi PV beberapa langkah ke depan. Perbedaanannya, penelitian ini berfokus pada konteks Pulau Selayar dan horizon <i>day-ahead</i> 24 jam.
Kim et al. [?]	Membandingkan model recurrent dan Transformer untuk prediksi daya PV <i>multi-step</i> .	Transformer, LSTM, RNN, GRU.	Transformer mampu menangkap hubungan temporal pada data PV. Penelitian ini menjadi dasar penggunaan Transformer sebagai baseline berbasis <i>attention</i> .
Hanif dan Mi [?]	Mengkaji penggunaan model Transformer untuk prediksi energi surya.	Kajian model Transformer.	Menunjukkan bahwa Transformer semakin relevan dalam prediksi energi surya. Relevan sebagai dasar teoritis penggunaan baseline Transformer.

Bersambung ke halaman berikutnya

Tabel 2.1 – lanjutan

Peneliti/Tahun	Tujuan Penelitian	Metode	Hasil dan Relevansi
Miao et al. [4]	Menganalisis pemanfaatan variabel iklim untuk memprediksi keluaran daya PV.	Backpropagation Neural Network.	Variabel meteorologis seperti radiasi dan suhu berkontribusi terhadap prediksi PV. Relevan sebagai dasar penggunaan variabel cuaca eksogen.
Mauladdawilah et al. [?]	Menganalisis seleksi fitur meteorologis untuk prediksi PV.	Deep feature selection dan LSTM.	Tidak semua variabel cuaca memberikan kontribusi yang sama. Relevan dengan penggunaan VSN pada TFT untuk seleksi variabel internal.
Nugroho et al. [?]	Memprediksi radiasi surya <i>day-ahead</i> pada iklim tropis Jawa-Bali, Indonesia.	Stacked LSTM, ARIMA, RNN.	Menunjukkan bahwa prediksi energi surya di wilayah tropis memiliki karakteristik musiman, dengan performa yang berbeda antara musim kering dan musim hujan. Relevan untuk memperkuat konteks Indonesia, meskipun targetnya radiasi surya, bukan daya aktif PV.
Stojcevski et al. [?]	Memprediksi keluaran daya PV pada sistem <i>grid-connected</i> di iklim hujan tropis Malaysia menggunakan model hibrida <i>deep learning</i> dan metaheuristik.	GRU-LSTM dengan <i>Fire Hawk Optimization</i> (FHO).	Menunjukkan efektivitas model hibrida GRU-LSTM dalam menangkap pola nonlinier data irradiansi iklim tropis ($R^2 > 0,996$). Relevan sebagai dasar konteks tantangan prediksi PV pada iklim tropis Asia Tenggara yang juga mencirikan kondisi Pulau Selayar.
Kantanet dan Kumyaito [?]	Mengembangkan model TFT dengan encoder-decoder GRU-LSTM untuk prediksi pembangkitan surya.	GRU-LSTM dalam kerangka TFT.	Menunjukkan pengembangan TFT untuk prediksi pembangkitan surya di konteks Asia Tenggara. Relevan sebagai pembandingan regional, namun tidak secara khusus membahas microgrid kepulauan terisolasi Indonesia.
Wang et al. [?]	Mengkaji penjadwalan koordinatif diesel, PV, dan <i>energy storage</i> pada <i>microgrid</i> terisolasi.	Optimasi penjadwalan.	Menunjukkan pentingnya koordinasi PV, penyimpanan energi, dan pembangkit diesel. Relevan untuk memperkuat urgensi prediksi PV pada Pulau Selayar.
Gallardo et al. [?]	Mengkaji sistem prediksi PV dan perannya dalam operasi sistem energi.	Review metode prediksi PV.	Menunjukkan bahwa prediksi PV penting sebagai dukungan informasi operasional sistem energi. Relevan dengan posisi penelitian ini sebagai pendukung perencanaan operasi.

Berdasarkan Tabel 2.1, terdapat beberapa persamaan antara penelitian terdahulu dengan penelitian ini. Pertama, sebagian besar penelitian sama-sama membahas prediksi daya PV atau radiasi surya sebagai permasalahan deret waktu yang dipengaruhi oleh kondisi historis dan variabel cuaca [4, ?, ?]. Kedua, beberapa penelitian telah menggunakan model *deep learning*, LSTM, Transformer, dan TFT untuk meningkatkan akurasi prediksi daya PV [?, ?, ?, ?]. Ketiga, penelitian terdahulu juga menunjukkan bahwa variabel cuaca seperti radiasi matahari, suhu udara, dan kondisi atmosfer memiliki peran penting dalam prediksi keluaran PV [4, ?, ?].

Meskipun demikian, terdapat beberapa perbedaan utama antara penelitian terdahulu dengan penelitian ini. Penelitian TFT untuk prediksi PV banyak dilakukan pada lokasi dan sistem kelistrikan yang berbeda, seperti fasilitas PV

di Jerman, Australia, India, Yordania, atau Thailand [?, ?, ?, ?]. Pada sisi lain, penelitian dari Indonesia dan Asia Tenggara lebih banyak membahas prediksi radiasi surya, potensi PV, atau model *deep learning* untuk sistem PV tertentu pada iklim tropis, tetapi belum secara spesifik menguji TFT untuk prediksi daya aktif PV *day-ahead* pada *microgrid* kepulauan terisolasi [?, ?, ?]. Dengan demikian, penelitian ini menempatkan Pulau Selayar sebagai konteks lokal yang penting karena sistemnya mengintegrasikan PLTS, BESS, dan PLTD dalam sistem kelistrikan kepulauan.

Perbedaan lainnya terletak pada struktur input model. Penelitian ini menggunakan data historis daya aktif PV, *irradiance* sensor, variabel cuaca ERA5 *reanalysis*, fitur turunan cuaca, dan fitur waktu. Dalam penerapan TFT, variabel historis diposisikan sebagai *observed historical inputs*, sedangkan fitur waktu dan fitur astronomis yang dapat dihitung secara deterministik diposisikan sebagai *known future inputs* [10]. Variabel cuaca ERA5 masa depan tidak digunakan sebagai *known future input* karena data ERA5 bersumber dari *reanalysis* [?]. Dengan demikian, penelitian ini berupaya menjaga rancangan eksperimen agar sesuai dengan ketersediaan informasi pada saat prediksi dilakukan.

Berdasarkan uraian tersebut, gap penelitian ini dirumuskan secara lebih hati-hati sebagai berikut: pada literatur yang ditinjau, penerapan TFT untuk prediksi daya aktif PV *day-ahead* 24 jam pada konteks *microgrid* kepulauan terisolasi Indonesia seperti Pulau Selayar masih belum banyak ditemukan [?, ?, ?, ?]. Oleh karena itu, penelitian ini menerapkan TFT sebagai model utama untuk menghasilkan prediksi daya aktif PV di Pulau Selayar. Transformer standar digunakan sebagai *baseline* utama berbasis *attention* karena paling dekat secara arsitektural dengan TFT, sedangkan persistence dan LSTM digunakan sebagai pembanding pendukung untuk memberikan evaluasi bertingkat dari pendekatan sederhana hingga model sekuensial *deep learning*.

2.2 Dasar Teori

Bagian ini memaparkan teori yang menjadi landasan penelitian. Pembahasan diawali dengan konsep PLTS dan daya aktif PV sebagai target prediksi, dilanjutkan dengan sistem *microgrid* terisolasi Pulau Selayar sebagai konteks penelitian. Selanjutnya dibahas variabel cuaca eksogen, PV forecasting, horizon *day-ahead*, metode prediksi daya PV, Temporal Fusion Transformer, *baseline* model, dan metrik evaluasi.

2.2.1 PLTS

Pembangkit Listrik Tenaga Surya (PLTS) merupakan sistem pembangkit energi listrik yang memanfaatkan teknologi fotovoltaiik untuk mengonversi radiasi matahari menjadi energi listrik. Sel surya mengubah energi cahaya menjadi arus listrik melalui efek fotovoltaiik, sehingga keluaran daya dapat digunak-

an secara langsung, disalurkan ke jaringan, atau diintegrasikan dengan sistem penyimpanan energi dan pembangkit pendukung lain [?]. Keluaran PLTS bersifat variabel karena produksinya dipengaruhi oleh kondisi cuaca, khususnya radiasi matahari, suhu udara, kelembapan, presipitasi, dan kondisi atmosfer lain [4, ?].

2.2.2 Daya Aktif PV

Variabel target dalam penelitian ini adalah daya aktif PV, yaitu daya listrik nyata yang dihasilkan oleh sistem PV dan tersedia pada sisi keluaran sistem setelah proses konversi energi oleh inverter. Dalam konteks sistem kelistrikan, daya aktif penting karena merepresentasikan komponen daya yang benar-benar dapat digunakan untuk memenuhi kebutuhan beban [?]. Pada sistem PLTS, nilai daya aktif dipengaruhi oleh intensitas radiasi matahari, temperatur modul, kondisi atmosfer, karakteristik inverter, serta dinamika operasi sistem [4, ?].

Dalam penelitian ini, daya aktif PV digunakan sebagai target prediksi, karena nilai tersebut secara langsung menggambarkan kontribusi PLTS terhadap pemenuhan kebutuhan daya pada sistem kelistrikan Pulau Selayar. Prediksi daya aktif PV *day-ahead* 24 jam diharapkan dapat menjadi informasi pendukung untuk memperkirakan kontribusi PLTS pada perencanaan operasi harian sistem kelistrikan lokal [?, ?].

2.2.3 Sistem Microgrid Terisolasi Pulau Selayar

Microgrid merupakan sistem kelistrikan lokal yang terdiri atas sumber pembangkit, beban, sistem penyimpanan energi, dan perangkat pengendali yang beroperasi dalam area tertentu. Pada *microgrid* terisolasi, sistem tidak memperoleh dukungan langsung dari jaringan listrik besar sehingga keseimbangan antara pembangkitan dan beban harus dikelola oleh sumber daya lokal yang tersedia. Pulau Selayar merupakan contoh sistem kelistrikan yang beroperasi sebagai *microgrid* kepulauan terisolasi, didukung oleh PLTS sekitar 1,3 MW, BESS sebesar 700 kW/873,6 kWh, 11 unit PLTD, dan beban puncak siang hari sekitar 4 MW [?].

Kapasitas PLTS yang cukup signifikan terhadap beban puncak menjadikan fluktuasi keluaran PV sebagai faktor operasional yang perlu diperhatikan. Ketika keluaran PV berubah akibat kondisi cuaca dan pola penyinaran matahari, sistem perlu menjaga keseimbangan daya menggunakan BESS atau PLTD yang tersedia secara lokal [?, ?]. Prediksi daya aktif PV *day-ahead* 24 jam dapat membantu memperkirakan kontribusi PLTS pada hari berikutnya, sehingga mendukung perencanaan pengoperasian BESS dan penjadwalan PLTD [?].

Dengan demikian, prediksi daya aktif PV dalam penelitian ini tidak dimaksudkan untuk melakukan optimasi *dispatch* PLTD atau kontrol BESS secara langsung, melainkan sebagai dukungan informasi awal untuk memperkirakan

kontribusi PV pada hari berikutnya.

2.2.4 Variabel Cuaca Eksogen

Keluaran daya PV memiliki hubungan langsung dengan kondisi cuaca karena energi yang diterima modul PV bergantung pada radiasi matahari yang mencapai permukaan modul. Selain radiasi, suhu udara memengaruhi efisiensi modul, sedangkan kelembapan, presipitasi, kecepatan angin, dan kondisi lapisan atmosfer dapat memengaruhi variasi produksi daya dalam skala waktu harian maupun intra-harian [4, ?]. Karakteristik ini menyebabkan prediksi daya PV yang hanya memanfaatkan histori daya berpotensi kurang memadai ketika pola cuaca berubah.

Dalam penelitian ini, variabel cuaca diposisikan sebagai variabel eksogen, yaitu variabel masukan yang memengaruhi target prediksi namun bukan target utama yang diprediksi. Data cuaca bersumber dari ERA5 *reanalysis* yang disediakan oleh Copernicus Climate Data Store [?]. Variabel eksogen yang digunakan mencakup radiasi matahari permukaan (*surface solar radiation downwards/ssrd*), radiasi termal permukaan (*surface thermal radiation downwards/strd*), suhu udara 2 meter (*t2m*), suhu titik embun 2 meter (*d2m*), presipitasi total (*tp*), komponen angin zonal 10 meter (*u10*), komponen angin meridional 10 meter (*v10*), hembusan angin 10 meter (*fg10*), serta tinggi lapisan batas atmosfer (*blh*). Selain variabel ERA5, penelitian ini juga memanfaatkan data *irradiance* sensor PLTS sebagai fitur historis tambahan.

2.2.5 PV Forecasting

PV forecasting merupakan proses memperkirakan keluaran daya PV pada waktu mendatang dengan memanfaatkan data historis, fitur waktu, dan variabel pendukung seperti kondisi cuaca [?, ?]. Berdasarkan horizon waktunya, prediksi daya PV dapat diklasifikasikan menjadi *very short-term*, *short-term*, *day-ahead*, dan *long-term forecasting* [?, ?]. Pemilihan horizon prediksi bergantung pada kebutuhan operasional sistem.

Dalam konteks *microgrid* Pulau Selayar, PV forecasting digunakan untuk memberikan estimasi awal terhadap daya aktif PV yang mungkin tersedia pada periode mendatang. Informasi tersebut dapat menjadi dasar pendukung dalam memahami kebutuhan perencanaan operasi harian, khususnya ketika sistem harus menyeimbangkan kontribusi PLTS dengan dukungan BESS dan PLTD [?, ?].

2.2.6 Day-Ahead Forecasting

Dalam penelitian ini, horizon yang digunakan adalah *day-ahead forecasting* 24 jam ke depan, yaitu skenario prediksi yang umum digunakan untuk mendukung perencanaan operasi energi pada hari berikutnya [?, ?]. Secara formal, model menggunakan urutan historis dari waktu $t - L + 1$ hingga t

untuk menghasilkan prediksi:

$$\{\hat{P}_{t+1}, \hat{P}_{t+2}, \dots, \hat{P}_{t+24}\} \quad (2.1)$$

dengan L menyatakan panjang jendela historis yang ditentukan melalui eksperimen. Horizon *day-ahead* dipilih karena relevan dengan kebutuhan perencanaan operasi harian pada *microgrid* terisolasi Pulau Selayar, khususnya untuk memperkirakan kontribusi PLTS dan mengantisipasi kebutuhan dukungan BESS serta PLTD pada hari berikutnya [?, ?].

2.2.7 Metode Prediksi Daya PV

Metode prediksi daya PV dapat dikelompokkan ke dalam pendekatan statistik, *machine learning*, *deep learning* sekuensial, dan model berbasis Transformer. Masing-masing pendekatan memiliki kelebihan dan keterbatasan, sehingga pemilihan metode perlu disesuaikan dengan karakteristik data, ketersediaan variabel masukan, horizon prediksi, serta kebutuhan interpretabilitas model [?, ?].

Metode statistik seperti ARIMA memiliki kelebihan berupa struktur model yang relatif sederhana, kebutuhan komputasi yang rendah, serta interpretasi yang mudah. Pendekatan ini dapat menjadi baseline yang berguna ketika pola deret waktu bersifat relatif stabil dan didominasi oleh komponen historis. Namun, pada prediksi daya PV, hubungan antara keluaran PV dan variabel cuaca sering bersifat nonlinier dan dipengaruhi oleh perubahan atmosfer yang cepat, sehingga model statistik murni dapat mengalami keterbatasan ketika harus memanfaatkan banyak variabel eksogen secara bersamaan; perbandingan dengan model berbasis *deep learning* menunjukkan bahwa LSTM dan GRU lebih efektif dalam konteks ini [?, ?].

Metode *machine learning* konvensional seperti Random Forest, Support Vector Regression, dan XGBoost mampu memodelkan hubungan nonlinier dan memanfaatkan banyak fitur masukan. Keunggulan metode ini terletak pada fleksibilitas dalam menangani fitur cuaca, fitur waktu, dan fitur historis. Namun, sebagian metode *machine learning* tidak secara eksplisit memodelkan urutan temporal, sehingga sering membutuhkan rekayasa fitur seperti *lag features*, *rolling statistics*, atau fitur musiman agar informasi waktu dapat dimanfaatkan dengan baik [?, ?].

Model *deep learning* seperti LSTM dan GRU relevan untuk data deret waktu karena memiliki mekanisme gerbang yang memungkinkan model mempelajari ketergantungan temporal dari data historis [?, ?]. LSTM banyak digunakan pada prediksi radiasi surya dan daya PV karena mampu menangkap pola sekuensial, termasuk pola harian dan musiman [?]. Meskipun demikian, LSTM standar belum secara eksplisit menyediakan mekanisme seleksi variabel yang terstruktur dan interpretabilitas variabel seperti yang disediakan oleh TFT [10, ?].


Model berbasis Transformer menawarkan mekanisme *self-attention* yang fleksibel untuk menangkap hubungan antarwaktu, termasuk hubungan jangka panjang pada data deret waktu multivariat [?, ?]. Namun, Transformer standar pada awalnya dikembangkan untuk pemodelan sekuens umum sehingga perlu disesuaikan untuk kasus *multi-horizon time series forecasting*. Secara khusus, Transformer standar tidak secara eksplisit membedakan input berdasarkan ketersediaannya terhadap horizon prediksi, seperti *observed historical inputs*, *known future inputs*, dan *static covariates*. Keterbatasan ini menjadi salah satu alasan penggunaan Temporal Fusion Transformer (TFT), karena TFT dirancang untuk prediksi deret waktu multivariat dan *multi-horizon*, dilengkapi seleksi variabel, komponen sekuensial, mekanisme *attention*, serta interpretabilitas model [10, ?].

Dengan demikian, metode statistik, *machine learning* konvensional, LSTM, dan Transformer tidak diposisikan sebagai metode yang tidak layak, melainkan sebagai pendekatan dengan karakteristik dan batas penggunaan masing-masing. Dalam penelitian ini, Transformer standar ditempatkan sebagai *baseline* utama berbasis *attention* untuk menilai nilai tambah rancangan TFT dibandingkan arsitektur *attention* dasar. Persistence tetap digunakan sebagai pembanding sederhana berbasis pola harian, sedangkan LSTM digunakan sebagai pembanding sekuensial *deep learning*.

2.2.8 Temporal Fusion Transformer (TFT)

Temporal Fusion Transformer (TFT) merupakan arsitektur *deep learning* untuk prediksi deret waktu multivariat dan multi-horizon. Model ini dirancang untuk mengolah berbagai jenis masukan, seperti variabel historis yang hanya diketahui sampai waktu pengamatan, variabel masa depan yang sudah diketahui, serta variabel statis yang menggambarkan karakteristik objek pengamatan [10]. Dalam konteks penelitian ini, TFT digunakan untuk memprediksi daya aktif PV *day-ahead* selama 24 jam dengan memanfaatkan histori daya aktif PV, *irradiance* sensor, variabel cuaca eksogen, serta fitur waktu.

Berbeda dengan model deret waktu konvensional yang umumnya menggunakan seluruh variabel masukan secara seragam, TFT memiliki mekanisme seleksi variabel yang memungkinkan model memberikan bobot berbeda terhadap setiap fitur. Mekanisme ini penting dalam prediksi daya aktif PV karena tidak semua variabel cuaca memberikan kontribusi yang sama pada setiap waktu. Sebagai contoh, radiasi matahari dapat menjadi fitur yang sangat dominan pada siang hari, sedangkan fitur waktu dan pola historis daya dapat lebih berperan dalam membentuk pola harian keluaran PV.



Gambar 2.1: Arsitektur *Temporal Fusion Transformer* (TFT) yang terdiri atas *static covariate encoders*, *variable selection network*, *LSTM encoder-decoder*, *gated residual network* (GRN), dan *interpretable multi-head attention* [10]

Gambar 2.1 menunjukkan bahwa TFT terdiri atas beberapa komponen utama, yaitu *variable selection network* (VSN), *static covariate encoder*, *LSTM encoder-decoder*, *gated residual network* (GRN), dan *interpretable multi-head attention*. Setiap komponen memiliki peran berbeda dalam mengolah informasi deret waktu, baik untuk menangkap pola lokal, memilih variabel yang relevan, maupun mempelajari hubungan temporal jangka panjang.

Komponen pertama adalah *variable selection network* (VSN). VSN digunakan untuk memilih variabel masukan yang paling relevan pada setiap waktu. Pada TFT, setiap variabel terlebih dahulu diproyeksikan ke dalam representasi laten, kemudian diberikan bobot kepentingan melalui mekanisme seleksi berbasis *softmax*. Secara umum, representasi gabungan dari sekumpulan variabel masukan dapat dituliskan sebagai berikut:

$$\tilde{\xi}_t = \sum_{j=1}^m v_{\chi_t}^{(j)} \xi_t^{(j)} \quad (2.2)$$

dengan $\tilde{\xi}_t$ merupakan representasi gabungan variabel pada waktu ke- t , $\xi_t^{(j)}$ merupakan representasi fitur ke- j , $v_{\chi_t}^{(j)}$ merupakan bobot seleksi variabel, dan m merupakan jumlah variabel masukan. Dalam penelitian ini, VSN relevan untuk membantu model membedakan kontribusi fitur seperti histori daya aktif PV, radiasi matahari, suhu udara, kelembapan, kecepatan angin, tutupan awan, dan fitur waktu.

Komponen kedua adalah *static covariate encoder*. Komponen ini digunakan untuk mengolah variabel statis yang tidak berubah sepanjang waktu, seperti informasi lokasi, kapasitas PLTS, atau karakteristik sistem apabila tersedia. Pada TFT, informasi statis tidak hanya digunakan sebagai fitur tambahan, tetapi juga dapat memengaruhi proses seleksi variabel dan pengolahan temporal melalui mekanisme *static enrichment*. Jika data statis tidak tersedia secara lengkap, TFT tetap dapat digunakan dengan berfokus pada masukan historis dan masukan masa depan yang diketahui.

Komponen ketiga adalah *LSTM encoder-decoder*. Bagian encoder digunakan untuk mengolah masukan historis, sedangkan decoder digunakan untuk mengolah masukan masa depan yang diketahui. Dalam penelitian ini, masukan historis dapat berupa histori daya aktif PV dan variabel cuaca eksogen yang diamati hingga waktu prediksi, sedangkan masukan masa depan dapat berupa fitur waktu seperti jam, hari, bulan, dan representasi siklik waktu. Keberadaan LSTM pada TFT membantu model menangkap pola temporal lokal dan urutan jangka pendek sebelum informasi tersebut diproses oleh mekanisme atensi.

Komponen keempat adalah *Gated Residual Network* (GRN). GRN merupakan salah satu komponen penting dalam TFT karena digunakan untuk melakukan transformasi fitur secara nonlinier sekaligus menjaga stabilitas aliran informasi melalui koneksi residual dan mekanisme gerbang. Secara konseptual, GRN memungkinkan model menentukan seberapa banyak informasi hasil transformasi yang perlu diteruskan dan seberapa banyak informasi awal yang perlu dipertahankan. Mekanisme ini berguna ketika beberapa fitur tidak selalu relevan pada setiap waktu, sehingga model dapat mengurangi pengaruh informasi yang kurang penting. Dengan demikian, GRN membantu TFT mengolah hubungan nonlinier antara daya aktif PV dan variabel cuaca tanpa mengabaikan struktur informasi awal.

Komponen kelima adalah *interpretable multi-head attention*. Pada Transformer standar, mekanisme atensi digunakan untuk mempelajari hubungan antarposisi dalam deret waktu melalui perhitungan *query*, *key*, dan *value* [?]. Secara umum, mekanisme *scaled dot-product attention* dapat dituliskan sebagai berikut:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.3)$$

dengan Q merupakan *query*, K merupakan *key*, V merupakan *value*, dan d_k merupakan dimensi dari *key*. Pada TFT, mekanisme atensi tersebut disesuaikan untuk kebutuhan prediksi multi-horizon melalui *interpretable multi-head attention*. Perbedaannya dengan *multi-head attention* pada Transformer standar adalah TFT menggunakan rancangan atensi yang lebih mudah diinterpretasikan, sehingga bobot atensi dapat dianalisis untuk melihat bagian historis

mana yang paling berpengaruh terhadap prediksi pada horizon tertentu. Hal ini penting dalam prediksi daya aktif PV karena model tidak hanya dituntut menghasilkan prediksi yang akurat, tetapi juga memberikan informasi mengenai pola temporal yang berkontribusi terhadap hasil prediksi.

Dalam penelitian ini, struktur masukan TFT dibagi menjadi tiga kelompok. Pertama, *observed historical inputs*, yaitu variabel yang hanya diketahui sampai waktu pengamatan, seperti histori daya aktif PV dan histori variabel cuaca. Kedua, *known future inputs*, yaitu variabel yang sudah diketahui pada horizon prediksi, seperti jam, hari, bulan, dan fitur waktu siklik. Ketiga, *static covariates*, yaitu informasi statis seperti lokasi atau kapasitas sistem apabila tersedia. Pembagian ini penting karena TFT secara khusus dirancang untuk membedakan jenis variabel berdasarkan ketersediaannya dalam proses prediksi.

Dengan kombinasi VSN, LSTM encoder-decoder, GRN, dan *interpretable multi-head attention*, TFT menjadi model yang sesuai untuk permasalahan prediksi daya aktif PV berbasis data deret waktu multivariat. Pada penelitian ini, TFT tidak diasumsikan secara langsung sebagai model yang pasti lebih baik dibandingkan model pembanding, tetapi diuji secara empiris melalui perbandingan performa terhadap model baseline. Evaluasi dilakukan menggunakan metrik kesalahan prediksi seperti MAE, RMSE, dan R^2 untuk menilai sejauh mana TFT mampu meningkatkan akurasi prediksi daya aktif PV *day-ahead* 24 jam di Pulau Selayar.

2.2.9 Baseline Model

Untuk menilai kelayakan kinerja TFT secara empiris, penelitian ini menggunakan tiga model pembanding, yaitu persistence, LSTM, dan Transformer standar. Transformer standar diposisikan sebagai *baseline* utama berbasis *attention* karena paling dekat dengan TFT dari sisi mekanisme pemodelan temporal. Persistence digunakan sebagai pembanding sederhana berbasis pola harian, sedangkan LSTM digunakan sebagai pembanding *deep learning* sekuensial [?, ?, ?]. Dengan susunan ini, evaluasi model dilakukan secara bertingkat tanpa menjadikan pengembangan baseline sebagai fokus utama penelitian.

2.2.9.1 Persistence

Persistence merupakan baseline sederhana yang mengasumsikan nilai daya PV pada hari berikutnya identik dengan nilai pada waktu yang sama dari hari sebelumnya. Baseline ini relevan untuk data PV karena pola harian akibat siklus penyinaran matahari bersifat berulang [?, ?]. Untuk horizon *day-ahead* 24 jam, persistence dirumuskan sebagai:

$$\hat{P}_{t+h} = P_{t+h-24}, \quad h = 1, 2, \dots, 24 \quad (2.4)$$

dengan $\hat{P}_{t+h}$ menyatakan prediksi pada horizon ke- h dan P_{t+h-24} menya-

takan nilai daya aktif PV pada waktu yang sama dari hari sebelumnya. Persistence digunakan untuk memastikan bahwa model yang lebih kompleks memberikan peningkatan kinerja dibandingkan asumsi pola harian sederhana [?].

2.2.9.2 Long Short-Term Memory

Long Short-Term Memory (LSTM) digunakan sebagai baseline *deep learning* berbasis model sekuensial. LSTM memiliki mekanisme gerbang yang mengatur informasi yang dipertahankan atau dilupakan selama pemrosesan urutan, sehingga relevan untuk mempelajari pola temporal pada data deret waktu [?, ?]. Dalam penelitian ini, LSTM baseline menggunakan arsitektur encoder-decoder sederhana untuk menghasilkan prediksi *multi-step* 24 jam ke depan. Input yang digunakan dibuat sebanding dengan TFT, yaitu histori daya aktif PV, variabel cuaca historis, *irradiance* sensor, dan fitur waktu. Perbandingan LSTM dengan TFT dilakukan untuk menilai apakah komponen tambahan TFT seperti VSN, GRN, dan *attention* memberikan peningkatan dibandingkan model sekuensial standar [10, ?].

2.2.9.3 Transformer

Transformer digunakan sebagai *baseline* utama berbasis *attention*. Dalam penelitian ini, istilah Transformer merujuk pada arsitektur Transformer standar yang disesuaikan untuk prediksi deret waktu multivariat. Penegasan ini diperlukan agar perbandingan berfokus pada perbedaan antara arsitektur *attention* dasar dan TFT, bukan pada perbandingan dengan seluruh keluarga model Transformer untuk deret waktu.

Secara umum, Transformer menggunakan mekanisme *self-attention*, *positional encoding*, dan lapisan *feed-forward* untuk mempelajari hubungan antarposisi dalam deret waktu secara paralel [?, ?]. Pada penelitian ini, Transformer standar menerima input multivariat yang disusun sebanding dengan input TFT, kemudian menghasilkan keluaran prediksi 24 jam ke depan. Berbeda dengan TFT, Transformer standar tidak menggunakan VSN untuk seleksi variabel, tidak menggunakan GRN sebagai mekanisme gerbang residual, dan tidak secara khusus membedakan struktur input ke dalam *observed historical inputs* dan *known future inputs* [10, ?]. Dengan demikian, perbandingan antara TFT dan Transformer standar memungkinkan penilaian apakah desain khusus TFT memberikan manfaat nyata dibandingkan model berbasis *attention* dasar pada prediksi daya aktif PV multivariat di Pulau Selayar.

2.2.10 Metrik Evaluasi

Evaluasi model prediksi daya aktif PV menggunakan Mean Absolute Error (MAE) dan Root Mean Square Error (RMSE) sebagai metrik utama. MAE dan RMSE umum digunakan dalam evaluasi prediksi daya PV karena dapat mengukur kesalahan prediksi dalam satuan yang sama dengan target daya [?, ?].

MAE mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi [?]:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.5)$$

RMSE mengukur akar dari rata-rata kuadrat kesalahan prediksi [?]:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.6)$$

dengan n menyatakan jumlah data, y_i menyatakan nilai aktual, dan $\hat{y}_i$ menyatakan nilai prediksi. MAE memberikan gambaran rata-rata kesalahan absolut secara linear, sedangkan RMSE memberikan penalti lebih besar terhadap kesalahan yang besar karena error dikuadratkan sebelum dirata-ratakan [?, ?].

Metrik berbasis persentase seperti Mean Absolute Percentage Error (MAPE) tidak digunakan sebagai metrik utama karena daya PV dapat bernilai nol atau mendekati nol, terutama pada malam hari. Ketika nilai aktual $y_i = 0$, MAPE menghasilkan pembagian dengan nol atau nilai yang tidak stabil, sehingga kurang sesuai untuk data daya PV harian yang memiliki periode tanpa produksi [?, ?]. Oleh karena itu, MAE dan RMSE dipilih karena lebih stabil secara numerik dan lebih mudah dikaitkan dengan implikasi operasional sistem *microgrid* terisolasi.

2.3 Posisi Penelitian

Berdasarkan kajian pustaka yang telah diuraikan, penelitian ini berada pada area prediksi daya aktif PV berbasis deret waktu multivariat dengan horizon *day-ahead* 24 jam pada *microgrid* kepulauan terisolasi Pulau Selayar [?, ?, ?]. Posisi ini dibangun dari tiga landasan. Pertama, literatur prediksi PV menunjukkan bahwa model berbasis *deep learning* dan Transformer semakin banyak digunakan untuk meningkatkan akurasi prediksi daya PV [?, ?, ?]. Kedua, studi dari Indonesia dan Asia Tenggara menunjukkan bahwa prediksi energi surya pada iklim tropis memiliki tantangan tersendiri karena dipengaruhi variasi musim, tutupan awan, dan dinamika atmosfer lokal [?, ?, ?]. Ketiga, konteks *microgrid* terisolasi menuntut informasi prediktif yang dapat membantu memperkirakan kontribusi PV terhadap operasi harian sistem yang didukung oleh BESS dan PLTD [?, ?].

Fokus utama penelitian ini adalah menghasilkan prediksi daya aktif PV yang dapat digunakan sebagai dukungan informasi awal untuk perencanaan operasi harian PLTS pada sistem kelistrikan Pulau Selayar. Dengan demikian, penelitian ini tidak berfokus pada optimasi *dispatch* PLTD, kontrol BESS,

atau simulasi operasi *microgrid*, melainkan pada penyediaan informasi prediktif mengenai kontribusi daya PV pada 24 jam ke depan [?, ?].

TFT digunakan sebagai model utama karena kemampuannya memproses *observed historical inputs* dan *known future inputs*, mekanisme seleksi variabel melalui VSN, pemrosesan nonlinier melalui GRN, serta interpretabilitas yang sesuai dengan karakteristik data PV multivariat [10, ?]. Pada penelitian ini, *observed historical inputs* mencakup histori daya aktif PV, *irradiance* sensor PLTS, variabel cuaca ERA5 (ssrd, strd, t2m, d2m, tp, u10, v10, fg10, blh), serta fitur turunan historis seperti kecepatan angin dan fitur posisi matahari pada periode observasi [?, 4]. Sementara itu, *known future inputs* dibatasi pada fitur waktu siklik dan fitur astronomis yang dapat dihitung secara deterministik karena nilainya dapat diketahui untuk horizon prediksi. Pembatasan ini dilakukan karena variabel cuaca ERA5 berasal dari data *reanalysis*, sehingga cuaca masa depan tidak digunakan sebagai input model untuk menghindari *data leakage* [10, ?].

Keunggulan TFT tidak diasumsikan secara apriori, melainkan diuji secara empiris melalui perbandingan dengan persistence, LSTM, dan Transformer standar [?, ?]. Dalam penelitian ini, Transformer standar diposisikan sebagai *baseline* utama berbasis *attention*, sedangkan persistence dan LSTM digunakan sebagai pembanding pendukung. Persistence mewakili pendekatan sederhana berbasis pola harian, LSTM mewakili model *deep learning* sekuensial, dan Transformer standar mewakili arsitektur *attention* dasar yang paling relevan untuk menilai nilai tambah komponen khusus TFT [?, ?, ?].

Kontribusi penelitian ini terletak pada tiga aspek. Pertama, dari sisi domain, penelitian ini menempatkan prediksi daya aktif PV pada konteks *microgrid* kepulauan terisolasi Pulau Selayar dengan konfigurasi PLTS, BESS, dan PLTD. Kedua, dari sisi model, penelitian ini menerapkan TFT untuk menghasilkan prediksi daya aktif PV *day-ahead* 24 jam dengan struktur input yang memperhatikan ketersediaan informasi pada saat prediksi dilakukan. Ketiga, dari sisi evaluasi dan interpretabilitas, penelitian ini mengevaluasi kelayakan kinerja TFT menggunakan MAE dan RMSE serta memanfaatkan mekanisme VSN dan *attention* untuk mengidentifikasi variabel dan periode waktu yang paling diperhatikan model. Dengan posisi tersebut, penelitian ini diharapkan dapat memberikan evaluasi empiris mengenai pemanfaatan TFT sebagai model prediksi daya aktif PV yang mendukung perencanaan operasi harian PLTS pada *microgrid* Pulau Selayar.

Bab III

Metodologi

Bab ini menguraikan tahapan penelitian dan alur pemodelan yang digunakan untuk memprediksi daya aktif *photovoltaic* (PV) berbasis *Temporal Fusion Transformer* (TFT) pada PLTS Pulau Selayar. Rangkaian penelitian mencakup desain penelitian, alur pemodelan, rencana kebutuhan data, pra-pemrosesan, pembagian data, skenario pengujian, algoritma pemodelan, evaluasi hasil, serta perangkat penelitian yang digunakan. Penamaan alur pemodelan digunakan karena fokus penelitian ini adalah pembangunan dan evaluasi model prediksi, bukan pembangunan sistem aplikasi operasional secara penuh.


3.1 Desain Penelitian

Penelitian ini dirancang menggunakan pendekatan eksperimental kuantitatif yang difokuskan pada pengembangan model prediksi deret waktu. Desain penelitian dimulai dari pengumpulan data operasional PLTS Pulau Selayar dan data cuaca ERA5 *reanalysis*. Data tersebut kemudian diproses melalui tahapan pra-pemrosesan untuk menyeragamkan format waktu, menangani nilai hilang, membersihkan nilai tidak wajar, serta membentuk fitur tambahan yang relevan terhadap produksi daya PV.

Model utama yang digunakan adalah *Temporal Fusion Transformer* (TFT). Model ini dipilih karena mendukung prediksi deret waktu multivariat dan multi-horizon serta dapat membedakan masukan historis (*observed historical inputs*) dan masukan masa depan yang sudah diketahui (*known future inputs*) [10]. Untuk menilai kelayakan performa TFT, penelitian ini menggunakan tiga model pembandingan, yaitu *persistence*, LSTM, dan Transformer standar. Transformer standar diposisikan sebagai *baseline* utama berbasis *attention*, sedangkan *persistence* dan LSTM digunakan sebagai pembandingan pendukung untuk melihat peningkatan kinerja dari model sederhana dan model sekuensial. Evaluasi dilakukan menggunakan metrik MAE dan RMSE, sedangkan interpretabilitas TFT dianalisis melalui bobot *Variable Selection Network* (VSN) dan bobot *attention*.

3.2 Alur Pemodelan

Alur pemodelan disusun secara sistematis agar proses penelitian dapat direplikasi dan dievaluasi dengan jelas. Secara umum, penelitian diawali dengan pengumpulan dan verifikasi data, dilanjutkan dengan integrasi data daya PV, *irradiance sensor*, dan cuaca ERA5, pembagian data secara kronologis, pra-pemrosesan, pembentukan dataset deret waktu, pelatihan model, evaluasi, dan analisis interpretabilitas. Diagram alir pemodelan ditunjukkan pada Gambar 3.1.



Gambar 3.1: Alur pemodelan prediksi daya aktif PV menggunakan *Temporal Fusion Transformer*

Gambar 3.1 menunjukkan alur pemodelan yang disusun dalam bentuk *pipeline* modular. Tahap awal dimulai dari verifikasi data daya aktif PV, *irradiance sensor*, dan data cuaca ERA5, kemudian dilanjutkan dengan sinkronisasi waktu, pra-pemrosesan, rekayasa fitur, serta pembagian data secara kronologis. Data yang telah siap kemudian dibentuk menjadi dataset *time series* untuk melatih model pembanding dan model utama TFT. Model pembanding terdiri atas *persistence*, LSTM, dan Transformer standar, dengan Transformer standar sebagai *baseline* utama berbasis *attention*. Kinerja model dievaluasi menggunakan MAE, RMSE, dan R^2 , sedangkan interpretabilitas TFT dianalisis melalui bobot *Variable Selection Network* dan *attention*. Input utama penelitian adalah histori daya PV, *irradiance sensor*, variabel cuaca ERA5 historis, dan fitur waktu; sedangkan output penelitian adalah prediksi daya aktif PV *day-ahead* 24 jam beserta informasi interpretabilitas dari model TFT.

3.3 Rencana Kebutuhan Data

Kebutuhan data dalam penelitian ini terdiri atas data operasional PLTS Pulau Selayar dan data cuaca ERA5 *reanalysis*. Data operasional PLTS Pulau Selayar periode Maret 2022–Agustus 2023 telah diperoleh melalui pembimbing penelitian, mencakup data daya aktif PV per jam dan irradiance sensor. Ketersediaan data ini memungkinkan tahap pemodelan dilaksanakan sesuai rencana.

Data daya aktif PV yang digunakan mencakup periode Maret 2022 hingga Agustus 2023 dengan resolusi temporal per jam. Data ini memuat nilai daya aktif PV sebagai variabel target dan *irradiance sensor* sebagai fitur historis tambahan. Periode sekitar 18 bulan digunakan sebagai dasar eksperimen awal, tetapi tetap diakui memiliki keterbatasan dalam merepresentasikan variasi musiman multi-tahun.

Data cuaca diperoleh dari ERA5 *reanalysis* melalui Copernicus Climate Data Store [?]. Data ERA5 digunakan sebagai variabel cuaca eksogen yang mendeskripsikan kondisi atmosfer di sekitar Pulau Selayar. Koordinat ERA5 yang digunakan bersifat aproksimasi, yaitu sekitar lintang $-6,0^\circ$ dan bujur $120,5^\circ$. Karena ERA5 memiliki resolusi spasial sekitar $0,25^\circ \times 0,25^\circ$, satu grid dapat mewakili area puluhan kilometer. Hal ini menjadi keterbatasan karena kondisi cuaca pada grid ERA5 belum tentu sepenuhnya sama dengan kondisi mikro di lokasi PLTS.

Dalam struktur input TFT, histori daya aktif PV, *irradiance sensor*, dan variabel ERA5 historis diperlakukan sebagai *observed historical inputs*. Fitur waktu, seperti jam, hari, bulan, hari dalam minggu, dan representasi siklus waktu, diperlakukan sebagai *known future inputs* karena nilainya dapat diketahui untuk horizon 24 jam ke depan. Variabel cuaca ERA5 masa depan tidak digunakan sebagai *known future inputs* karena ERA5 merupakan data *reanalysis*; penggunaan nilai ERA5 masa depan berpotensi menimbulkan *data leakage* pada evaluasi model.

Tabel 3.1: Rencana kebutuhan data penelitian

Komponen	Keterangan
Variabel target	Daya aktif PV per jam sebagai target prediksi.
Data lokal PLTS	Daya aktif PV dan <i>irradiance sensor</i> pada PLTS Pulau Selayar.
Data cuaca ERA5	<i>ssrd</i> , <i>strd</i> , <i>t2m</i> , <i>d2m</i> , <i>tp</i> , <i>u10</i> , <i>v10</i> , <i>fg10</i> , dan <i>blh</i> .
Periode data	Maret 2022 sampai Agustus 2023.
Resolusi waktu	Per jam (<i>hourly</i>).
Struktur input TFT	<i>Observed historical inputs</i> : daya PV, <i>irradiance sensor</i> , dan ERA5 historis; <i>known future inputs</i> : fitur waktu dan fitur astronomis deterministik.
Horizon prediksi	24 jam ke depan (<i>day-ahead forecasting</i>).

3.4 Pra-pemrosesan Data

Data mentah dari sistem PLTS dan ERA5 memiliki karakteristik sumber, format, dan satuan yang berbeda. Oleh karena itu, pra-pemrosesan dilakukan untuk memastikan data berada dalam format yang konsisten dan siap digunakan dalam pemodelan.

3.4.1 Penyelarasan dan Integrasi Data

Seluruh data diselaraskan berdasarkan *timestamp* per jam. Data PV, *irradiance sensor*, dan variabel ERA5 digabungkan menggunakan indeks waktu yang sama. Apabila terdapat perbedaan zona waktu, seluruh *timestamp* dikonversi ke zona waktu yang konsisten sebelum proses integrasi dilakukan. Setelah itu, dibentuk rangkaian waktu penuh dari awal hingga akhir periode penelitian untuk mendeteksi celah waktu yang hilang.

3.4.2 Pembersihan dan Penanganan Nilai Hilang

Pembersihan data dilakukan dengan memeriksa nilai duplikat, format waktu tidak valid, serta nilai yang tidak masuk akal secara fisik. Nilai daya aktif PV dan *irradiance* yang bernilai negatif dikoreksi menjadi nol setelah diverifikasi sebagai artefak pencatatan. Nilai hilang pada variabel cuaca ERA5 ditangani menggunakan interpolasi linear apabila celah waktunya pendek. Untuk daya aktif PV, nilai hilang pada periode siang hari tidak langsung diisi nol karena dapat merepresentasikan gangguan pencatatan data. Baris yang mengalami imputasi diberi penanda agar dapat ditelusuri pada tahap evaluasi kualitas data.

3.4.3 Deteksi Anomali dan Normalisasi Data

Deteksi anomali PV dilakukan secara sederhana menggunakan median lokal pada periode siang hari. Deteksi hanya diterapkan ketika *solar elevation* lebih besar dari 10° dan irradiance sensor lebih besar atau sama dengan 200 W/m^2 . Untuk setiap waktu t , dihitung median lokal daya PV menggunakan jendela tujuh jam, yaitu dari $t - 3$ hingga $t + 3$. Titik data ditandai sebagai anomali rendah apabila memenuhi Persamaan 3.1.

$$P_t < 0,3 \times \text{MedianLocal}(P_{t-3:t+3}) \quad (3.1)$$

Titik yang terdeteksi sebagai anomali tidak langsung dihapus, tetapi diberi *flag* agar dapat dianalisis lebih lanjut. Setelah data bersih, normalisasi dilakukan menggunakan parameter yang dihitung hanya dari data latih. Parameter tersebut kemudian diterapkan pada data validasi dan data uji untuk mencegah kebocoran informasi dari data masa depan.

3.4.4 Rekayasa Fitur

Rekayasa fitur dilakukan untuk membantu model menangkap pola temporal dan pengaruh cuaca terhadap daya PV. Fitur yang dibentuk meliputi fitur waktu, fitur posisi matahari, dan fitur turunan cuaca. Fitur waktu mencakup jam, hari, bulan, hari dalam minggu, serta representasi siklik menggunakan sinus dan kosinus. Fitur posisi matahari mencakup *solar zenith*, *solar azimuth*, *solar elevation*, dan penanda siang hari. Fitur turunan cuaca mencakup *wind speed*, selisih suhu udara dan titik embun, serta penanda hujan sederhana berdasarkan presipitasi.

Seleksi fitur berbasis korelasi Pearson hanya digunakan sebagai analisis eksploratif awal. Karena hubungan daya PV dan variabel cuaca dapat bersifat nonlinier, Pearson tidak digunakan sebagai satu-satunya dasar penghapusan fitur. Keputusan akhir penggunaan fitur dilakukan berdasarkan performa pada data validasi dan, khusus untuk TFT, dapat dibantu oleh bobot VSN.

3.5 Pembagian Data

Data dibagi secara kronologis menjadi data latih, data validasi, dan data uji dengan proporsi 70%, 15%, dan 15%. Pembagian dilakukan berdasarkan urutan waktu, bukan secara acak, karena data yang digunakan merupakan deret waktu. Data latih digunakan untuk membangun model, data validasi digunakan untuk memilih konfigurasi hyperparameter terbaik, dan data uji digunakan untuk mengevaluasi kinerja akhir model.

Dengan periode data sekitar 18 bulan, bagian data uji hanya merepresentasikan sekitar 2–3 bulan terakhir dari periode pengamatan. Oleh karena itu, hasil penelitian dibatasi pada periode data yang tersedia dan tidak digeneralisasikan secara berlebihan untuk seluruh variasi musiman multi-tahun.

Strategi pembagian kronologis ini dipilih untuk menjaga agar proses evaluasi lebih mendekati kondisi prediksi nyata, yaitu model dilatih menggunakan data masa lalu dan diuji pada data setelahnya.

3.6 Skenario Pengujian

Skenario pengujian dirancang untuk mengevaluasi performa model utama TFT dibandingkan model pembanding, sekaligus menguji kontribusi *irradiance sensor* sebagai fitur lokal. Skenario pengujian dibagi menjadi eksperimen utama dan eksperimen tambahan. Eksperimen utama wajib dilakukan karena langsung menjawab rumusan masalah penelitian, sedangkan eksperimen tambahan digunakan untuk memperkuat analisis apabila waktu dan sumber daya komputasi memungkinkan.

Eksperimen utama (wajib):

1. **E0 – Persistence:** model sederhana yang memprediksi daya PV berdasarkan nilai pada jam yang sama di hari sebelumnya. Skenario ini digunakan sebagai baseline dasar berbasis pola harian.
2. **E1 – LSTM:** model sekuensial berbasis *deep learning* yang menerima histori daya PV, *irradiance sensor*, variabel ERA5 historis, dan fitur waktu historis. Skenario ini digunakan sebagai baseline temporal berbasis recurrent neural network.
3. **E2 – Transformer standar:** model berbasis *attention* standar yang disesuaikan untuk prediksi deret waktu multivariat. Skenario ini diposisikan sebagai baseline utama berbasis *attention* untuk menilai apakah rancangan khusus TFT memberikan peningkatan dibandingkan arsitektur Transformer standar.
4. **E3 – TFT dengan *irradiance sensor*:** model utama menggunakan histori daya PV, variabel ERA5 historis, fitur turunan cuaca, fitur waktu, fitur astronomis, dan *irradiance sensor* sebagai fitur historis lokal.

Eksperimen tambahan (jika waktu komputasi memungkinkan):

5. **E4 – TFT tanpa *irradiance sensor*:** *ablation study* untuk mengukur kontribusi *irradiance sensor* terhadap akurasi prediksi TFT, dengan menghapus variabel tersebut dari masukan model.
6. **E5 – Variasi *lookback window*:** pengujian panjang histori $L \in \{24, 48, 72\}$ jam pada model terbaik dari eksperimen utama.

Pada eksperimen utama, panjang *lookback window* awal ditetapkan $L = 24$ jam karena merepresentasikan satu siklus harian penuh. Horizon prediksi ditetapkan 24 jam ke depan sehingga target model adalah prediksi daya aktif

PV dari $t + 1$ hingga $t + 24$. Secara umum, pasangan input dan target dapat dituliskan sebagai berikut:

$$X_{t-L+1:t} \rightarrow \hat{Y}_{t+1:t+24} = \{\hat{P}_{t+1}, \hat{P}_{t+2}, \dots, \hat{P}_{t+24}\} \quad (3.2)$$

Dalam eksperimen TFT, variabel historis seperti daya aktif PV, *irradiance sensor*, dan ERA5 historis hanya digunakan sampai waktu prediksi t . Fitur waktu dan fitur astronomis deterministik dapat disediakan untuk horizon $t + 1$ sampai $t + 24$ karena nilainya dapat dihitung tanpa mengetahui kondisi cuaca aktual masa depan. Pembatasan ini dilakukan untuk menjaga evaluasi agar tidak mengalami *data leakage*.

3.7 Algoritma

Penelitian ini membangun sistem prediksi daya aktif PV dengan pendekatan deret waktu multivariat. Pendekatan algoritmik penelitian dijabarkan pada subbagian berikut.

3.7.1 Algoritma Umum Prediksi Daya Aktif PV

Alur algoritma umum dimulai dari pembentukan dataset gabungan antara data daya PV dan variabel cuaca. Setelah data diproses dan dibagi secara kronologis, model dilatih untuk menghasilkan prediksi daya aktif PV 24 jam ke depan. Prosedur umum penelitian ditunjukkan pada Algoritma 1.

Algorithm 1 Prosedur pelatihan dan evaluasi sistem prediksi daya aktif PV

- 1: **procedure** PREDIKSIDAYAPVTFT(D, L, H)
 - 2: **Input:** Dataset gabungan D , panjang *lookback* L , horizon $H = 24$
 - 3: **Output:** Prediksi daya aktif PV, nilai MAE, RMSE, dan informasi interpretabilitas TFT
 - 4: Selaraskan data daya PV, irradiance sensor, dan ERA5 berdasarkan *timestamp*
 - 5: Bersihkan data, tangani nilai hilang, dan tandai anomali PV
 - 6: Bentuk fitur waktu, fitur posisi matahari, dan fitur turunan cuaca
 - 7: Bagi data secara kronologis menjadi data latih, validasi, dan uji
 - 8: Hitung parameter normalisasi dari data latih dan terapkan ke seluruh partisi
 - 9: Bentuk dataset *sliding window* $X_{t-L+1:t}$ dan target $Y_{t+1:t+H}$
 - 10: Latih model pembanding: *persistence*, LSTM, dan Transformer standar
 - 11: Latih model utama TFT menggunakan data latih dan validasi
 - 12: Pilih model terbaik berdasarkan performa validasi
 - 13: Evaluasi model pada data uji menggunakan MAE dan RMSE
 - 14: Ambil bobot VSN dan *attention* dari TFT untuk analisis interpretabilitas
 - 15: **end procedure**
-

3.7.2 Model Baseline

Model baseline digunakan untuk menilai apakah TFT memberikan peningkatan performa yang layak dibandingkan pendekatan pembanding. Baseline pertama adalah *persistence*, yaitu model sederhana yang menggunakan nilai daya PV pada jam yang sama di hari sebelumnya. Untuk horizon 24 jam, model ini dirumuskan sebagai berikut:

$$\hat{P}_{t+h} = P_{t+h-24}, \quad h = 1, 2, \dots, 24 \quad (3.3)$$

Baseline kedua adalah LSTM, yang digunakan untuk merepresentasikan model sekuensial berbasis *deep learning*. Baseline ketiga adalah Transformer standar, yaitu model berbasis *attention* yang disesuaikan untuk prediksi deret waktu multivariat. Transformer standar diposisikan sebagai *baseline* utama berbasis *attention* agar perbandingan dengan TFT dapat menunjukkan apakah komponen khusus TFT, seperti *Variable Selection Network*, *Gated Residual Network*, dan pemisahan input historis serta input masa depan yang diketahui, memberikan peningkatan kinerja dibandingkan arsitektur Transformer dasar.

3.7.3 Model Temporal Fusion Transformer

TFT digunakan sebagai model utama karena mampu menangani prediksi multi-horizon dengan input multivariat. Pada penelitian ini, input TFT dibagi

menjadi dua kelompok utama. Kelompok pertama adalah *observed historical inputs*, yaitu variabel yang hanya diketahui sampai waktu prediksi dilakukan, seperti histori daya PV, *irradiance sensor*, variabel ERA5 historis, dan fitur turunan cuaca. Kelompok kedua adalah *known future inputs*, yaitu fitur yang dapat diketahui untuk 24 jam ke depan, seperti jam, hari, bulan, hari dalam minggu, fitur waktu siklik, dan fitur astronomis deterministik.

Variabel cuaca ERA5 masa depan tidak digunakan sebagai *known future input* karena ERA5 merupakan data *reanalysis*. Jika nilai cuaca ERA5 masa depan dimasukkan ke model, maka eksperimen dapat mengalami *data leakage*. Oleh karena itu, variabel ERA5 hanya digunakan sebagai input historis, sedangkan fitur waktu digunakan sebagai input masa depan yang diketahui.

3.7.4 Analisis Interpretabilitas TFT

Setelah model TFT terbaik diperoleh, analisis interpretabilitas dilakukan menggunakan dua informasi utama. Pertama, bobot VSN digunakan untuk melihat kontribusi relatif setiap variabel masukan, misalnya daya PV historis, irradiance sensor, radiasi ERA5, suhu udara, angin, presipitasi, dan fitur waktu. Kedua, bobot *attention* digunakan untuk melihat periode historis yang paling diperhatikan model ketika menghasilkan prediksi. Analisis ini digunakan sebagai informasi pendukung untuk memahami perilaku model, bukan sebagai bukti hubungan kausal antara variabel cuaca dan daya aktif PV.

3.8 Evaluasi dan Analisis Hasil

Evaluasi dilakukan pada dua kondisi. Pertama, evaluasi *full-day* mencakup seluruh 24 jam prediksi, termasuk periode malam hari. Kedua, evaluasi *daytime* dibatasi pada jam-jam ketika *solar elevation* lebih besar dari 5° dan nilai daya aktif PV aktual lebih besar dari 0 kW. Pemisahan ini diperlukan karena pada periode malam hari seluruh model dapat menghasilkan prediksi mendekati nol seperti nilai aktualnya, sehingga metrik *full-day* dapat terlihat rendah dan kurang merepresentasikan kemampuan model pada periode produksi aktif. Oleh karena itu, evaluasi *daytime* digunakan sebagai acuan utama dalam perbandingan antara model TFT dan model pembanding.

Metrik utama yang digunakan adalah *Mean Absolute Error* (MAE) dan *Root Mean Square Error* (RMSE). MAE digunakan untuk melihat rata-rata kesalahan absolut antara nilai aktual dan nilai prediksi, sedangkan RMSE digunakan untuk memberikan penalti lebih besar terhadap kesalahan prediksi yang tinggi. Selain itu, nilai koefisien determinasi (R^2) digunakan sebagai metrik tambahan untuk melihat kemampuan model dalam menjelaskan variasi data aktual.

Hasil evaluasi disajikan dalam bentuk tabel perbandingan nilai MAE, RMSE, dan R^2 untuk setiap model, yaitu *persistence*, LSTM, Transformer standar, dan TFT. Model TFT dinyatakan memiliki kinerja lebih baik apabila

menghasilkan nilai MAE dan RMSE yang lebih rendah dibandingkan *baseline* terbaik pada data uji. Untuk memperjelas peningkatan kinerja, dihitung pula persentase penurunan kesalahan TFT terhadap *baseline* terbaik menggunakan Persamaan 3.4.

$$\text{Reduction}(\%) = \frac{E_{\text{baseline terbaik}} - E_{\text{TFT}}}{E_{\text{baseline terbaik}}} \times 100\% \quad (3.4)$$

dengan E menyatakan nilai kesalahan prediksi, yaitu MAE atau RMSE. Apabila TFT menghasilkan penurunan MAE dan RMSE minimal 5% dibandingkan *baseline* terbaik, maka kinerja TFT dianggap memberikan peningkatan yang cukup bermakna dalam penelitian ini. Apabila penurunan kesalahan kurang dari 5%, maka hasil diperlakukan sebagai peningkatan terbatas. Sebaliknya, apabila TFT tidak menghasilkan kesalahan lebih rendah dibandingkan *baseline* terbaik, maka hipotesis utama tidak terdukung.

Selain evaluasi kuantitatif, hasil prediksi juga dianalisis secara visual melalui grafik perbandingan antara nilai aktual dan nilai prediksi. Analisis visual digunakan untuk melihat kemampuan model mengikuti pola harian daya PV, terutama pada pagi hari, siang hari, dan sore hari. Pada model TFT, analisis tambahan dilakukan terhadap bobot VSN dan bobot *attention* untuk mengidentifikasi variabel masukan dan periode historis yang paling diperhatikan model. Hasil interpretabilitas ini digunakan sebagai informasi pendukung dalam pembahasan, bukan sebagai bukti hubungan kausal antarvariabel.

3.9 Perangkat Penelitian

Eksperimen pemodelan dalam penelitian ini dilaksanakan menggunakan perangkat lunak dan perangkat keras sebagai berikut:

- **Bahasa pemrograman:** Python 3.10 atau versi yang lebih baru.
- **Pengolahan data:** pandas dan NumPy untuk manipulasi data, integrasi timestamp, dan pembentukan dataset deret waktu.
- **Akses data ERA5:** cdsapi untuk mengunduh data ERA5 dari Copernicus Climate Data Store.
- **Fitur posisi matahari:** pvlib untuk menghitung posisi matahari, *solar elevation*, dan fitur astronomis lain yang relevan.
- **Pemodelan deep learning:** PyTorch dan PyTorch Forecasting untuk implementasi LSTM, Transformer standar, dan TFT.
- **Evaluasi dan visualisasi:** scikit-learn, SciPy, Matplotlib, dan Seaborn untuk metrik evaluasi, uji statistik sederhana, dan visualisasi hasil prediksi.

- **Lingkungan eksekusi:** Jupyter Notebook atau Google Colab.
- **Perangkat keras:** GPU Google Colab seperti NVIDIA T4 atau GPU lokal yang tersedia. Apabila GPU tidak tersedia, eksperimen tetap dapat dijalankan pada CPU dengan konsekuensi waktu pelatihan yang lebih lama.

Spesifikasi perangkat keras aktual, seperti jenis CPU, GPU, kapasitas RAM, dan lingkungan eksekusi, akan dilaporkan pada bagian hasil eksperimen. Hal ini dilakukan agar waktu pelatihan dan performa model dapat diinterpretasikan sesuai dengan sumber daya komputasi yang digunakan.

Daftar Pustaka

- [1] S. P. Kanugrahan, D. F. Hakam, and H. Nugraha. Techno-economic analysis of indonesia power generation expansion to achieve economic sustainability and net zero carbon 2050. *Sustainability*, 14(15):9038, 2022.
- [2] Airin Marsaulina Hutabarat, Rinaldy Dalimi, Rudy Setiabudy, and Budi Sudiarto. Techno-economics analysis of off-grid solar photovoltaic (pv) systems in remote areas in indonesia for rural village electrification: Case study of pantar island. *Journal of Physics: Conference Series*, 3139(1):012075, 2025.
- [3] Muhammad Very Nugroho, Andhika Prastawa, Fajril Mardiansah, Arya Rezavidi, Ahmad Fudholi, and Sudirman Palaloi. A stacked lstm model for day-ahead solar irradiance forecasting under tropical seasons in java-bali. *International Journal of Power Electronics and Drive Systems (IJPEDS)*, 15(3):1878–1891, 2024.
- [4] Yijia Miao, Stephen Siu Yu Lau, Kenneth Kin Nang Lo, Yehao Song, Hongzhan Lai, Jin Zhang, Yiqi Tao, and Yue Fan. Harnessing climate variables for predicting pv power output: A backpropagation neural network analysis in a subtropical climate region. *Solar Energy*, 264:111979, 2023.
- [5] PPSDM KEBTKE. *Smart Grid: Handbook Microgrid*. Kementerian Energi dan Sumber Daya Mineral Republik Indonesia, 2023. Dokumen Pelatihan, 10 Juli 2023.
- [6] Jialin Wang, Shuai Cao, Rentai Li, and Wei Xu. Energy symbiosis in isolated multi-source complementary microgrids: Diesel–photovoltaic–energy storage coordinated optimization scheduling and system resilience analysis. *Energies*, 18(21):5741, 2025.
- [7] Nifat Sultana and Narumasa Tsutsumida. A review on data-driven methods for solar energy forecasting. *Applied Energy*, 400:126631, 2025.
- [8] Putri Nor Liyana Mohamad Radzi, Saad Mekhilef, Noraisyah Mohamed Shah, Muhammad Naveed Akhter, Mehdi Seyedmahmoudian, and Alex

- Stojcevski. Optimizing solar power forecasting with metaheuristic algorithms and deep learning models for photovoltaic grid connected systems. *Scientific Reports*, 15(1):40045, 2025.
- [9] Qingsong Wen, Tian Zhou, Chaoli Zhang, Weiqi Chen, Ziqing Ma, Junchi Yan, and Liang Sun. Transformers in time series: A survey. In *Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence*, pages 6778–6786, 2023.
- [10] Bryan Lim, Sercan Ö Arik, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021.
- [11] M. López Santos, X. García-Santiago, F. Echevarría Camarero, G. Blázquez Gil, and P. Carrasco Ortega. Application of temporal fusion transformer for day-ahead pv power forecasting. *Energies*, 15(14):5232, 2022.
- [12] M. Islam, S. S. Shuvo, J. A. Shohan, and O. Faruque. Forecasting of pv plant output using interpretable temporal fusion transformer model. In *2023 North American Power Symposium (NAPS)*, pages 1–6. IEEE, 2023.
- [13] Sameer Al-Dahidi, Hussein Alahmer, Bilal Rinchi, Abdullah Bani-Abdullah, Mohammad Alrbai, Osama Ayadi, and Loiy Al-Ghussain. Multistep pv power forecasting using deep learning models and the reptile search algorithm. *Results in Engineering*, 27:106265, 2025.

Lampiran